

Lista 5 - Inteligência Artificial

Arthur de Sá Braz de Matos

- 1- Número de itensSets (com confiança ≥ 0.3) 1, 2 e 3 respectivamente: 3, 3 e 1.
Número de regras (com suporte ≥ 0.8) = 7

id	Leite	Café	cerveja	Pão	Manteiga	Amoço	Frango
1	X	X	X	X	X	X	X
2	X	X	X	X	X	X	X
3	X	X	X	X	X	X	X
4	X	X	X	X	X	X	X
5	X	X	X	X	X	X	X
6	X	X	X	X	X	X	X
7	X	X	X	X	X	X	X
8	X	X	X	X	X	X	X
9	X	X	X	X	X	X	X
10	X	X	X	X	X	X	X
Sup. ≥ 0.3 Conf. ≥ 0.8							
Item sets 1 - P(3)							
Leite = 2/10 X, Manteiga = 3/10 X							
Café = 3/10 X, Amoco = 2/10 X							
Cerveja = 3/10 X, Frango = 3/10 X							
Pão = 3/10 X							
Item sets 2 - P(3)							
Café e pão = 3/10 X							
Café e manteiga = 3/10 X							
Pão e manteiga = 4/10 X							
Item sets 3 - P(4)							
Café, pão e manteiga = 3/10 X							
Regras							
Café \rightarrow Pão = 3/3 = 1 X							
Pão \rightarrow Café = 3/5 = 0.6 X							
Café \rightarrow Manteiga = 3/3 = 1 X							
Manteiga \rightarrow Café = 3/5 = 0.6 X							
Pão \rightarrow Manteiga = 4/5 = 0.8 X							
Manteiga \rightarrow Pão = 4/5 = 0.8 X							
Café e Pão \rightarrow Manteiga = 3/3 = 1 X							
Pão e Café \rightarrow Manteiga = 3/5 = 0.6 X							
Manteiga e Pão \rightarrow Café = 3/4 = 0.75 X							
Manteiga e Café \rightarrow Pão = 3/3 = 1 X							
Pão e Manteiga \rightarrow Café = 3/3 = 1 X							
Terá 7 regras							

2- LINK PARA ACESSAR O CÓDIGO DAS SEGUINTE QUESTÕES:

<https://colab.research.google.com/drive/1H1Ox1feuHSqNz1Ro9t8JYZufDi25C-1A?usp=sharing>

	Antecedente	Consequente	suporte	confianca	lift
0	[Café]	[Manteiga]	0.3	1.0	2.0
1	[Café]	[Pão]	0.3	1.0	2.0
2	[Manteiga]	[Pão]	0.4	0.8	1.6
3	[Pão]	[Manteiga]	0.4	0.8	1.6
4	[Café]	[Pão, Manteiga]	0.3	1.0	2.5
5	[Café, Manteiga]	[Pão]	0.3	1.0	2.0
6	[Pão, Café]	[Manteiga]	0.3	1.0	2.0

3-

```
Itemset: ['Café', 'Manteiga'], Suporte: 0.30
Itemset: ['Pão', 'Café'], Suporte: 0.30
Itemset: ['Café', 'nan'], Suporte: 0.30
Itemset: ['Pão', 'Manteiga'], Suporte: 0.40
Itemset: ['Manteiga', 'nan'], Suporte: 0.50
Itemset: ['Pão', 'nan'], Suporte: 0.50
Itemset: ['Pão', 'Café', 'Manteiga'], Suporte: 0.30
Itemset: ['Café', 'Manteiga', 'nan'], Suporte: 0.30
Itemset: ['Pão', 'Café', 'nan'], Suporte: 0.30
Itemset: ['Pão', 'Manteiga', 'nan'], Suporte: 0.40
Itemset: ['Pão', 'Café', 'Manteiga', 'nan'], Suporte: 0.30
```

4-

['Arroz'], Suporte: 0.80	['Feijão', 'Café', 'Leite'], Suporte: 0.40	['Cerveja', 'Manteiga', 'Café', 'Leite'], Suporte: 0.40
['Cerveja'], Suporte: 0.80	['Manteiga', 'Feijão', 'Café'], Suporte: 0.30	['Cerveja', 'Pão', 'Café', 'Leite'], Suporte: 0.40
['Feijão'], Suporte: 0.80	['Feijão', 'Pão', 'Café'], Suporte: 0.30	['Cerveja', 'nan', 'Café', 'Leite'], Suporte: 0.50
['Leite'], Suporte: 0.80	['nan', 'Feijão', 'Café'], Suporte: 0.50	['Cerveja', 'Manteiga', 'Pão', 'Café'], Suporte: 0.30
['nan'], Suporte: 1.00	['Manteiga', 'Café', 'Leite'], Suporte: 0.50	['Cerveja', 'nan', 'Manteiga', 'Café'], Suporte: 0.40
['Feijão', 'Arroz'], Suporte: 0.70	['Pão', 'Café', 'Leite'], Suporte: 0.50	['Cerveja', 'nan', 'Pão', 'Café'], Suporte: 0.40
['nan', 'Arroz'], Suporte: 0.80	['nan', 'Café', 'Leite'], Suporte: 0.60	['Manteiga', 'Feijão', 'Café', 'Leite'], Suporte: 0.30
['Café', 'Leite'], Suporte: 0.60	['Manteiga', 'Pão', 'Café'], Suporte: 0.40	['Feijão', 'Pão', 'Café', 'Leite'], Suporte: 0.30
['Manteiga', 'Café'], Suporte: 0.50	['nan', 'Manteiga', 'Café'], Suporte: 0.50	['nan', 'Feijão', 'Café', 'Leite'], Suporte: 0.40
['Pão', 'Café'], Suporte: 0.50	['nan', 'Pão', 'Café'], Suporte: 0.50	['Manteiga', 'Feijão', 'Café', 'nan'], Suporte: 0.30
['nan', 'Café'], Suporte: 0.70	['Feijão', 'Cerveja', 'Leite'], Suporte: 0.50	['nan', 'Feijão', 'Pão', 'Café'], Suporte: 0.30
['Cerveja', 'Leite'], Suporte: 0.70	['nan', 'Feijão', 'Cerveja'], Suporte: 0.60	['Manteiga', 'Pão', 'Café', 'Leite'], Suporte: 0.40
['Manteiga', 'Cerveja'], Suporte: 0.40	['Manteiga', 'Cerveja', 'Leite'], Suporte: 0.40	['nan', 'Manteiga', 'Café', 'Leite'], Suporte: 0.50
['Pão', 'Cerveja'], Suporte: 0.40	['Pão', 'Cerveja', 'Leite'], Suporte: 0.40	['nan', 'Pão', 'Café', 'Leite'], Suporte: 0.50
['nan', 'Cerveja'], Suporte: 0.80	['nan', 'Cerveja', 'Leite'], Suporte: 0.70	['nan', 'Manteiga', 'Pão', 'Café'], Suporte: 0.40
['Feijão', 'nan'], Suporte: 0.80	['nan', 'Manteiga', 'Cerveja'], Suporte: 0.40	['nan', 'Manteiga', 'Pão', 'Café'], Suporte: 0.40
['Manteiga', 'Leite'], Suporte: 0.50	['nan', 'Pão', 'Cerveja'], Suporte: 0.40	['nan', 'Feijão', 'Cerveja', 'Leite'], Suporte: 0.50
['Pão', 'Leite'], Suporte: 0.50	['Feijão', 'Manteiga', 'Leite'], Suporte: 0.30	['Manteiga', 'Pão', 'Cerveja', 'Leite'], Suporte: 0.30
['nan', 'Leite'], Suporte: 0.80	['Feijão', 'Pão', 'Leite'], Suporte: 0.30	['nan', 'Manteiga', 'Cerveja', 'Leite'], Suporte: 0.40
['Manteiga', 'Pão'], Suporte: 0.40	['Feijão', 'nan', 'Leite'], Suporte: 0.60	['nan', 'Pão', 'Cerveja', 'Leite'], Suporte: 0.40
['Manteiga', 'nan'], Suporte: 0.50	['nan', 'Feijão', 'Manteiga'], Suporte: 0.30	['nan', 'Manteiga', 'Pão', 'Cerveja'], Suporte: 0.30
['nan', 'Pão'], Suporte: 0.50	['nan', 'Feijão', 'Pão'], Suporte: 0.30	['nan', 'Feijão', 'Manteiga', 'Leite'], Suporte: 0.30
['Feijão', 'Café', 'Arroz'], Suporte: 0.40	['Manteiga', 'Pão', 'Leite'], Suporte: 0.40	['nan', 'Feijão', 'Pão', 'Leite'], Suporte: 0.30
['Leite', 'Café', 'Arroz'], Suporte: 0.40	['Manteiga', 'nan', 'Leite'], Suporte: 0.50	['nan', 'Manteiga', 'Pão', 'Leite'], Suporte: 0.40
['Manteiga', 'Café', 'Arroz'], Suporte: 0.30	['nan', 'Pão', 'Leite'], Suporte: 0.50	['Cerveja', 'nan', 'Café', 'Arroz', 'Leite'], Suporte: 0.30
['Pão', 'Café', 'Arroz'], Suporte: 0.30	['nan', 'Manteiga', 'Pão'], Suporte: 0.40	['nan', 'Feijão', 'Café', 'Arroz', 'Leite'], Suporte: 0.30
['nan', 'Café', 'Arroz'], Suporte: 0.50	['Cerveja', 'Leite', 'Café', 'Arroz'], Suporte: 0.30	['Manteiga', 'nan', 'Café', 'Arroz', 'Leite'], Suporte: 0.30
['Feijão', 'Cerveja', 'Arroz'], Suporte: 0.50	['Cerveja', 'nan', 'Café', 'Arroz'], Suporte: 0.30	['nan', 'Café', 'Arroz', 'Pão', 'Leite'], Suporte: 0.30
['Leite', 'Cerveja', 'Arroz'], Suporte: 0.50	['nan', 'Feijão', 'Café', 'Arroz'], Suporte: 0.40	['Cerveja', 'nan', 'Feijão', 'Arroz', 'Leite'], Suporte: 0.40
['nan', 'Cerveja', 'Arroz'], Suporte: 0.60	['Leite', 'Manteiga', 'Café', 'Arroz'], Suporte: 0.30	['Cerveja', 'nan', 'Feijão', 'Café', 'Leite'], Suporte: 0.30
['Leite', 'Feijão', 'Arroz'], Suporte: 0.50	['Leite', 'Pão', 'Café', 'Arroz'], Suporte: 0.30	['Cerveja', 'Manteiga', 'Café', 'Pão', 'Leite'], Suporte: 0.30
['Feijão', 'nan', 'Arroz'], Suporte: 0.70	['Leite', 'nan', 'Café', 'Arroz'], Suporte: 0.40	['Cerveja', 'Manteiga', 'nan', 'Café', 'Leite'], Suporte: 0.40
['Leite', 'Manteiga', 'Arroz'], Suporte: 0.30	['nan', 'Manteiga', 'Café', 'Arroz'], Suporte: 0.30	['Cerveja', 'nan', 'Café', 'Pão', 'Leite'], Suporte: 0.40
['Leite', 'Pão', 'Arroz'], Suporte: 0.30	['nan', 'Pão', 'Café', 'Arroz'], Suporte: 0.30	['Cerveja', 'Manteiga', 'nan', 'Café', 'Pão'], Suporte: 0.30
['Leite', 'nan', 'Arroz'], Suporte: 0.60	['Leite', 'Feijão', 'Cerveja', 'Arroz'], Suporte: 0.40	['Manteiga', 'nan', 'Feijão', 'Café', 'Leite'], Suporte: 0.30
['Manteiga', 'nan', 'Arroz'], Suporte: 0.30	['nan', 'Feijão', 'Cerveja', 'Arroz'], Suporte: 0.50	['nan', 'Feijão', 'Café', 'Pão', 'Leite'], Suporte: 0.30
['nan', 'Pão', 'Arroz'], Suporte: 0.30	['Leite', 'nan', 'Cerveja', 'Arroz'], Suporte: 0.50	['Manteiga', 'nan', 'Café', 'Pão', 'Leite'], Suporte: 0.40
['Cerveja', 'Café', 'Leite'], Suporte: 0.50	['Leite', 'Feijão', 'nan', 'Arroz'], Suporte: 0.50	['Cerveja', 'Manteiga', 'nan', 'Pão', 'Leite'], Suporte: 0.30
['Cerveja', 'Manteiga', 'Café'], Suporte: 0.40	['Leite', 'Manteiga', 'nan', 'Arroz'], Suporte: 0.30	['Cerveja', 'Manteiga', 'nan', 'Café', 'Pão', 'Leite'], Suporte: 0.30
['Cerveja', 'Pão', 'Café'], Suporte: 0.40	['Leite', 'nan', 'Pão', 'Arroz'], Suporte: 0.30	
['Cerveja', 'nan', 'Café'], Suporte: 0.50	['Cerveja', 'Feijão', 'Café', 'Leite'], Suporte: 0.30	
	['Cerveja', 'nan', 'Feijão', 'Café'], Suporte: 0.30	

5- A biblioteca mlxtend é uma extensão de ferramentas para Python, projetada para facilitar tarefas em machine learning, análise de dados e pré-processamento. Um de seus recursos é a análise de regras de associação. O processo de geração dessas regras envolve duas funções principais: “apriori” e “association_rules”. O primeiro passo nesse processo é a identificação de conjuntos de itens que aparecem frequentemente em uma base de transações. Para isso, a função “apriori” analisa uma base de dados binária, na qual cada linha representa uma transação e cada coluna representa um item específico. Dessa forma, o valor 1 indica a presença de um item em uma transação, enquanto 0 indica sua ausência. A função calcula o suporte, que é a proporção de transações nas quais um conjunto de itens específico aparece. Assim, “apriori” retorna apenas os conjuntos de itens que atendem a um suporte mínimo, ou seja, que aparecem com uma frequência igual ou superior a um valor predefinido. Esse conjunto de itens frequentes será usado para descobrir associações. Uma vez identificados os conjuntos frequentes de itens, a função “association_rules” permite a criação de regras de associação entre eles. Essa função aplica métricas como confiança e lift para medir a força das associações entre os itens. Usando essas métricas, “association_rules” gera um conjunto de regras que indica a relação

entre itens, como “se o item A está presente, então o item B também tende a estar”. Para filtrar essas regras, a função permite definir um valor mínimo para a métrica escolhida, de modo que somente associações fortes sejam consideradas. O fluxo para criação de regras de associação usando mlxtend começa com a preparação dos dados no formato binário adequado. Em seguida, o algoritmo “apriori” extrai os conjuntos frequentes de itens com base no suporte mínimo. Por fim, a função “association_rules” é aplicada a esses conjuntos para calcular as regras de associação com base na confiança ou em outra métrica definida. Assim, o mlxtend oferece uma estrutura eficiente e flexível para análise de padrões, sendo uma ferramenta para análises de dados.

6- O artigo fornece uma análise detalhada das diversas técnicas de visualização utilizadas para interpretar os resultados da mineração de regras de associação (ARM). O texto inicia discutindo a crescente tendência em machine learning (ML) em direção à inteligência artificial explicável, que visa tornar os modelos de ML mais interpretáveis e confiáveis para os usuários. Isso é especialmente relevante na ARM, onde os algoritmos podem gerar um grande número de regras que podem ser difíceis de entender sem métodos de visualização adequados. O objetivo é coletar e analisar as técnicas de visualização para ARM desde seu surgimento até o presente. A metodologia baseia-se em uma busca sistemática na literatura, realizada em três grandes bancos de dados: ACM Digital Library, IEEEExplore e Google Scholar. Os autores formularam perguntas de pesquisa para guiar sua análise, concentrando-se no desenvolvimento de métodos de visualização para ARM, desafios, pacotes de software disponíveis e direções futuras. O artigo oferece uma visão detalhada dos métodos tradicionais de visualização para ARM, discutindo suas características e aplicações. Ele também explora novas ideias em visualização, como mapas de metrô e diagramas de Sankey, que visam aprimorar a usabilidade e a interpretabilidade dos resultados da ARM. Os autores destacam vários desafios na visualização da ARM, incluindo a necessidade de técnicas apropriadas que possam escalar com a complexidade dos dados e a importância da qualidade dos dados. Eles enfatizam que as visualizações devem facilitar a comunicação eficaz e a compreensão de informações complexas. A conclusão sugeriu possíveis caminhos para futuras pesquisas em visualização de ARM, particularmente em campos como ciências biológicas e médicas. Os autores incentivam uma exploração mais aprofundada de técnicas de visualização inovadoras que possam melhorar a interpretabilidade das regras de associação. De modo geral, o artigo reforça o papel crítico da visualização na ARM, defendendo o desenvolvimento contínuo e o refinamento de métodos para aprimorar a compreensão do usuário e os processos de tomada de decisão na análise de dados.